

HW11

Execution description

Experimental results

【標準化資料後異常偵測結果】

資料的異常點數量：593

【無標準化資料異常偵測結果】

資料的異常點數量：9116

觀察結果可以發現，**未標準化的資料**所偵測出的異常點數量（9116 筆）遠遠高於**標準化後的資料**（593 筆）。

造成此差異的原因如下：

1. SVM 對特徵尺度非常敏感：


One-Class SVM（尤其是使用 RBF 核）會計算樣本間的距離。若特徵值的範圍差異很大（例如某些欄位值範圍是 01000，而有些是 01），模型會受到**高變異特徵的主導**，導致學習的邊界偏斜或異常偵測失衡。


2. 標準化使各特徵貢獻均衡：


標準化（Z-score scaling）讓所有特徵都轉換成均值為 0、標準差為 1 的分布，讓模型在進行樣本距離計算時，**每個特徵的貢獻同等重要**，使模型的邊界更穩定、更準確地判斷正常與異常資料。


3. 未標準化造成過多誤判：

在未標準化的情況下，模型容易誤將原本正常的樣本視為異常值（因為它們在某些高變異欄位的數值偏離平均值），進而大幅提高異常偵測的數量。









由上到下的樹高分別為 3, 5, 7, 無限制

混淆矩陣截圖中顯示：

- 深度愈高，預測結果越接近實際值。
- 誤判數量明顯下降。

結果通常會在訓練集上變好

原因如下：

- **樹越深 → 拆分越細**，每個葉節點更能對應到一個純淨的類別。
- 在訓練資料上，模型能**記住更多細節與例外情形**，因此準確率上升。

但不代表在測試集上會更好

過度增深會導致：

- **過擬合 (Overfitting)**：模型記住訓練資料中的雜訊，對未知資料泛化能力變差。
 - **複雜度高、解釋性下降**：難以理解和維護模型。
-

特徵重要性的變化

- **淺層樹**幾乎只依賴最具區辨力的特徵（如 Elevation）。
- **深層樹**會使用更多特徵，例如距離、方向、不同時間的 Hillshade、各類 Soil Type 等，能捕捉更多分類依據。

Conclusion

標準化對於使用 One-Class SVM 進行異常偵測是極為重要的預處理步驟。沒有標準化可能會導致模型學習到不合理的邊界，進而誤判大量正常樣本為異常點。因此，**在實際應用中建議務必先對數據進行標準化處理再訓練 SVM 模型。**

- 增加決策樹的深度確實能**提高訓練準確率**，在這次的實驗中也提升了整體的 Accuracy。
- 但深度增加後需留意**是否過擬合**，建議搭配驗證集或交叉驗證來確保泛化能力。
- 最佳深度應根據資料集特性與模型表現評估，**不應盲目追求深度越深越好。**

Discussion

本次作業比較了不同 `max_depth` 設定下的 Decision Tree 模型表現。結果顯示，樹的深度增加時，準確率逐漸上升，從深度 3 的 0.60 提升至無限制深度的 0.78。這是因為更深的樹能夠學習更多訓練資料的細節，提升分類能力。然而，過深的樹可能會導致過擬合，影響模型在未知資料上的泛化能力。因此，實務上應根據驗證結果選擇合適深度，而非單純追求高準確率。